

Les bases de Machine Learning

2025/2026

Devoir

Livrable : fichiers ipynb mises à jour + un fichier pdf contenant l'ensemble des résultats

Problème de régression N°1: dataset synthétique

Niveau de complexité du problème : simple

Rappel sur les réseaux de neurones

Un réseau de neurones se compose de :

- Inputs
- 0 ou plusieurs couches cachées
- Une seule couche de sortie
- Chaque couche contient un ou plusieurs neurones

Le réseau de neurones le plus simple se compose de :

- Inputs
- 0 couche cachée
- Une couche de sortie avec un seul neurone

Un neurone se compose de :

- Inputs : $x_1, x_2, \dots, x_m$
- Paramètres : bias, $w_1, w_2, \dots, w_m$
- weighted sum: $z = \text{bias} + w_1.x_1 + w_2.x_2 + \dots + w_m.x_m$
- Output = $f(z)$ ou f est une fonction d'activation

Exercice 1 : Régression basée sur les réseaux de neurones avec tensorflow & keras

Ouvrir le fichier `devoir_regression.ipynb`

Répondre aux questions tout en mettant à jour le fichier.

1) Préparation de données – code source section 1, fourni

1. a) Générer un dataset synthétique
1. b) Extraire la partie features : $X = \text{np.column_stack}((X1, X2))$ et y
1. c) Diviser le dataset en training set (80%) et test set (20%)
1. d) Expliquer l'importance de division en training set et test set


Compléter les codes sources du fichier `.ipynb`

Là où il ya des ?, il faut la remplacer par l'instruction adéquate

2) Modèle de réseau de neurones

2-a) Architecture de réseau de neurones :

2-a-1) Proposition d'une architecture



2-a-2) à partir de la nature du dataset, établir les inputs du réseau de neurones

2-a-3) à partir de la nature du dataset, établir le nombre de neurones à mettre dans outputlayer du réseau de neurones.

2-a-4) à partir de la nature de target, établir la fonction d'activation de la couche d'output.

2-b) sans aucune couche cachée, créer un modèle basé sur un réseau de neurones « model_nn » qui correspond à ce problème

2-c) compiler le modèle :

optimizer= adam, cost function adequate, metrics: mse

2-d) entrainer le modèle en utilisant **4000** epochs

si les ressources de mémoire de votre machine sont insuffisantes, mettre uniquement 100 epochs

2-e) préciser ce que fait la fonction fit

2-f) quel est le nombre de paramètres du réseau

-faire un calcul à la main pour la première itération ET afficher le détail du réseau

2-g) afficher les paramètres du réseau de neurones

2-h) dessiner le réseau de neurones en utilisant les paramètres trouvés

2-i) dans quels cas il est important de faire des régulations (tuning)

3) Prédiction en utilisant le modèle

3-a) En utilisant le modèle « model_nn », faire les prédictions en utilisant X_test. Stocker le résultat dans yhat_nn

3-b) En utilisant les paramètres du modèle, faire une prédiction sans utilisation de predict de tensorflow.keras.Sequential

4) Évaluation du modèle

4-a) Performance du modèle sur **training set**

- Évaluer le modèle en utilisant mse, r2
- Calculer $y_{\text{test}} - \hat{y}_{\text{lin_reg}}$
- Tracer le graphique des résidus($\hat{y}_{\text{lin_reg}}, y_{\text{test}} - \hat{y}_{\text{lin_reg}}$)
- Interpréter les résultats

4-b) Performance du modèle sur **test set**

4-c) À quoi peut servir, évaluer le modèle en utilisant training set et test set en même temps

Exercice 2 : Régression basée sur la régression linéaire sans utilisation de sklearn (Version avec matrices)

Compléter les codes sources du fichier .ipynb

Là où il ya des ?, il faut la remplacer par l'instruction adéquate

1) Calculs élémentaires pour une itération

Et on suppose la dataset suivant

X1	X2	Y
1	2	10
3	4	20
5	6	30
7	8	40

On suppose le modèle suivant :

bias=0.1, $W = \begin{bmatrix} 0.2 \\ 0.3 \end{bmatrix}$

a) Calcul de la prédiction :

b) Calcul des erreurs

c) Calcul des gradients

d) Mise à jour du modèle

NB. Pour les différents calculs, écrire des bouts de code qui font les calculs

- 2) Compléter le code source de manière à entrainer le modèle
- 3) Évaluer le modèle
- 4) Comparer les résultats obtenus avec le modèle de régression linéaire avec sklearn

Problème de classification N°1: dataset de diabetes

Niveau de complexité du problème : simple

Exercice 1 : Classification basée sur neural network avec utilisation de tensorflow

Ouvrir le fichier `devoir_classification.ipynb`

Répondre aux questions tout en mettant à jour le fichier.

Compléter les codes sources du fichier `.ipynb`

Là où il ya des **?**, il faut la remplacer par l'instruction adéquate

1) Préparation de données

- 1-a) importer le data de `diabetes.csv`
- 1-b) Extraire la partie features X et la target y
- 1-c) Diviser le dataset en training set (80) et test set (20%)

2) Modèle de réseau de neurones

2-a) Architecture de réseau de neurones :

2-a-1) à partir de la nature du dataset, établir les inputs du réseau de neurones

2-a-2) à partir de la nature du dataset, établir le nombre de neurones à mettre dans outputlayer du réseau de neurones.

2-a-3) à partir de la nature de target, établir la fonction d'activation de la couche d'output.

2-b) sans aucune couche cachée, créer un modèle basé sur un réseau de neurones « `model_nn` » qui correspond à ce problème

2-c) compiler le modèle :

optimizer= adam, cost function adequate, metrics: accuracy, precision

2-d) entrainer le modèle en utilisant **1000** epochs

si les ressources de mémoire de votre machine sont insuffisantes, mettre uniquement 100 epochs

2-e) préciser ce que fait la fonction fit

2-f) quel est le nombre de paramètres du réseau

-faire un calcul à la main ET afficher le détail du réseau

2-g) afficher les paramètres du réseau de neurones

2-h) dessiner le réseau de neurones en utilisant les paramètres trouvés

2-i) dans quels cas il est important de faire des régulations (tuning)

3) Prédiction en utilisant le modèle

3-a) En utilisant le modèle « model_nn », faire les prédictions en utilisant X_test. Stocker le résultat dans yhat_nn

3-b) En utilisant les paramètres du modèle, faire une prédiction sans utilisation de predict de tensorflow.keras.Sequential mais en utilisant des matrices

4) Évaluation du modèle

4-a) Performance du modèle sur **training set**

- Évaluer le modèle en utilisant mse, r2
- Calculer $y_{\text{test}} - \hat{y}_{\text{lin_reg}}$
- Tracer le graphique des résidus ($\hat{y}_{\text{lin_reg}}, y_{\text{test}} - \hat{y}_{\text{lin_reg}}$)
- Interpréter les résultats

4-b) Performance du modèle sur **test set**

4-c) À quoi peut servir, évaluer le modèle en utilisant training set et test set en même temps

Exercice 2 : Classification basée sur la régression logistique sans utilisation de sklearn

(Version avec matrices)

Compléter les codes sources du fichier .ipynb

Là où il ya des ?, il faut la remplacer par l'instruction adéquate

- 1) Utiliser le même dataset de l'exercice 1
- 5) Pourquoi développer des modèles sans utilisation de librairies ?
- 6) Quelles sont les principales étapes à suivre
- 7) Comment les dérivées de cost function par rapport aux paramètres peuvent participer à la mise à jour du modèle
- 8) Compléter le code source de manière à entrainer le modèle
- 9) Évaluer le modèle
- 10) Comparer les résultats obtenus avec le modèle de régression linéaire avec sklearn

